ECOLE MAROCAINE DES SCIENCES DE L'INGENIEUR
Membre de HONORIS UNITED UNIVERSITIES

HONORIS UNITED UNIVERSITIES

Compte rendu de travaux pratiques
TP04 AutoML

Ingénierie Informatique et Réseaux

Intelligence Artificielle & Sciences des Données

Sous le thème

Explorer les plateformes AutoML et MLOps low-code

Réalisé par :

Zakaria Abdelbaki

Amine Khabot

Ismail Lahlou

Rayane Hafidi

Filière : AI | Groupe : G6

Module :

Déploiement d'IA

Année universitaire 2026-2027

1. Objectifs, données et protocole

Ce TP compare une référence logistique, le meilleur réglage manuel du TP2 et une recherche AutoML locale avec FLAML. L'objectif est de mesurer le rendement du budget de calcul, d'inspecter les essais et de comprendre les limites de l'automatisation, en particulier la fuite de données.

Élément	Configuration du travail
Groupe	Zakaria Abdelbaki, Amine Khabot, Ismail Lahlou et Rayane Hafidi - AI, G6
Données	5 000 transactions synthétiques ; 568 fraudes ; donnees.py du TP2, graine 7
Découpage externe	3 750 observations train / 1 250 test ; random_state=42
Environnement	Python 3.12.14 ; FLAML 2.7.0 ; scikit-learn 1.9.1
Matériel	Intel Core i7-1185G7 ; 4 cœurs / 8 processeurs logiques
Suivi	MLflow 3.17.1 ; expérience tp4-automl ; port local 5001

Une séparation entre recherche et évaluation

FLAML reçoit uniquement le jeu d'entraînement dans fit(). Il utilise une validation interne pour choisir sa famille et ses hyperparamètres. Le jeu de test externe est utilisé à la fin, pour mesurer le F1 du gagnant. Les deux références réutilisent exactement le même découpage.

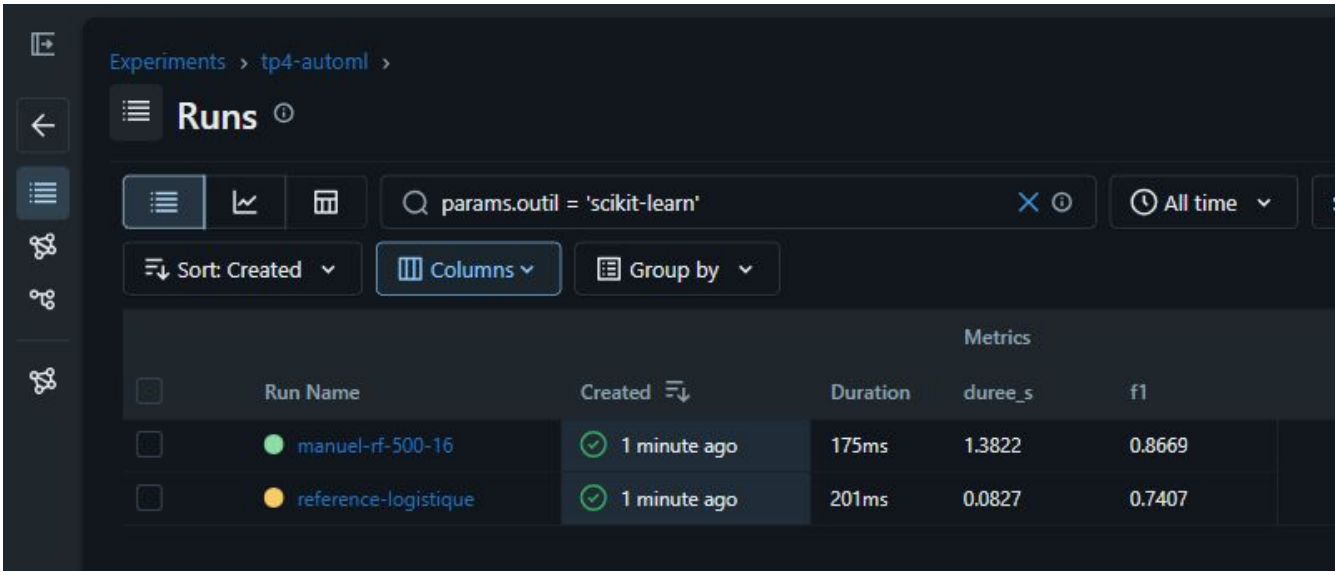
```
transactions v1 (5000)
  -> train (3750) -> validation interne FLAML -> gagnant
  -> test externe (1250) --------------------> F1 final
```

Les recherches de 10, 30, 60 et 120 s sont indépendantes. La graine vaut 42, mais le nombre de candidats dépend de la vitesse de la machine. Un budget n'est pas une promesse de durée totale exacte. Les durées présentées mesurent fit(), hors installation et journalisation MLflow.

Python 3.12 a été choisi pour rester dans les versions prises en charge par FLAML 2.7. Le plan B n'a pas été utilisé. Le port 5001 évite le conflit avec le serveur du TP2, conservé sur 5000.

2. Bloc A : établir les références

references.py entraîne une régression logistique avec max_iter=1000 et une forêt aléatoire de 500 arbres, profondeur maximale 16 et graine 42. Le temps d'entraînement et le F1 sont enregistrés dans MLflow.



Capture 1 - Expérience tp4-automl : les deux références et leur F1.

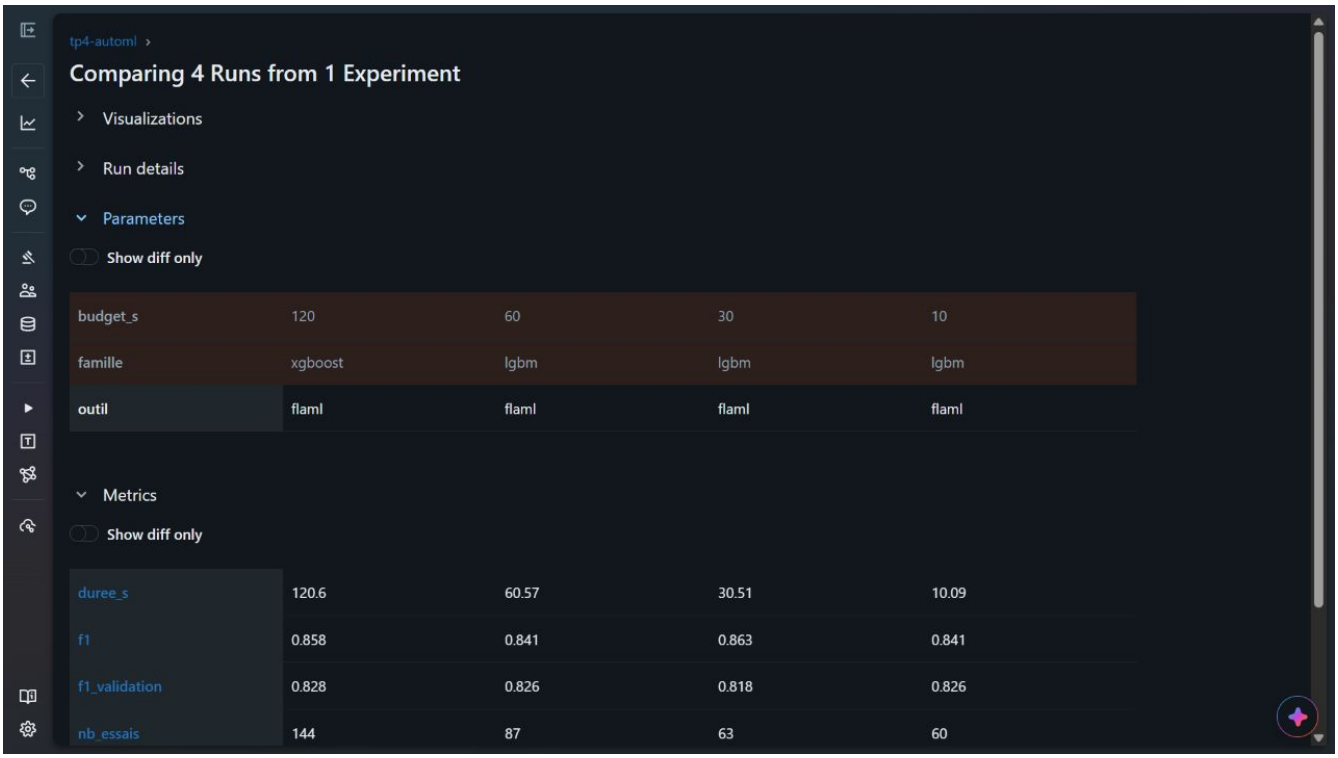
Approche	F1 test	Entraînement mesuré
Référence logistique	0,7407	0.0827 s
RF manuel 500/16	0,8669	1.3822 s

Le RF manuel retrouve le F1 de référence du TP2 (0,8669). Le score de la logistique est 0,7407. Ce premier modèle constitue un repère simple et rapide ; il ne faut pas confondre son temps de fit avec tout le travail humain de compréhension des données.

Aucun redécoupage spécifique à une famille n'est effectué : les indices train et test sont communs et disjoints. Les tags conservent les auteurs, le groupe, le commit et le SHA-256 des données.

3. Bloc B : rechercher sous quatre budgets

automl.py explore plusieurs familles et réglages avec metric=f1, seed=42 et log_type=all. Un run récapitulatif est conservé par budget ; la journalisation MLflow automatique interne de FLAML est désactivée pour éviter des runs supplémentaires.

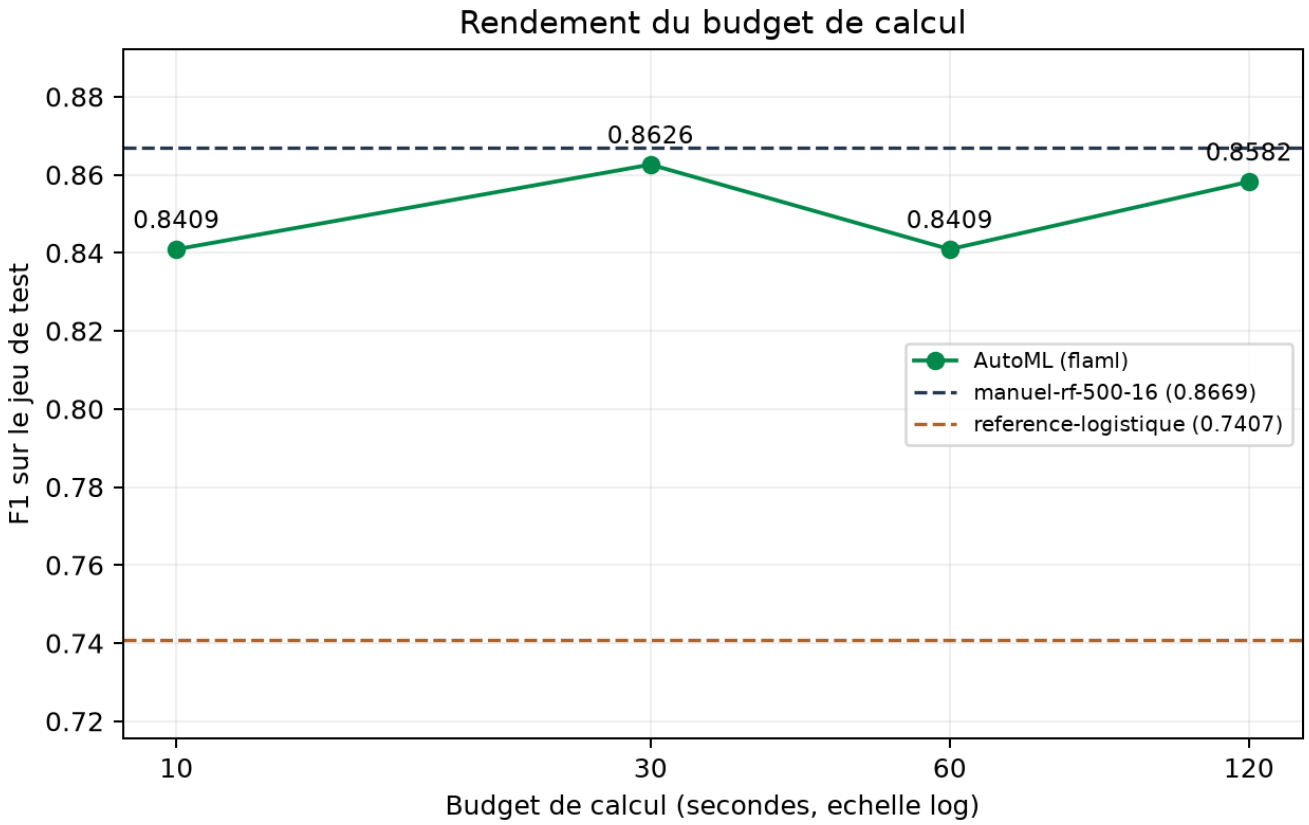


Capture 2 - Comparaison des quatre runs FLAML dans MLflow : budgets, familles, F1 de test et de validation.

Budget	Famille retenue	F1 test	F1 validation	Durée fit	Essais
10 s	lgbm	0,8409	0,8262	10.09 s	60
30 s	lgbm	0,8626	0,8181	30.51 s	63
60 s	lgbm	0,8409	0,8262	60.57 s	87
120 s	xgboost	0,8582	0,8277	120.56 s	144

Le F1 de validation sert à sélectionner le candidat ; le F1 externe décrit sa performance finale. Leur différence n'est pas un écart de calcul : ils proviennent de jeux distincts. La comparaison des scores externes entre budgets est descriptive et ne déclenche pas une nouvelle optimisation sur le test.

4. Bloc B : rendement du temps de calcul



Capture 3 - Graphique original reports/rendement.png, affiché intégralement avec les deux références.

Parmi ces quatre recherches, le meilleur F1 externe est 0,8626, pour un budget de 30 s et la famille lgbm. À 60 s, le F1 est 0,8409, contre 0,8669 pour le RF manuel, soit -0.0260 point F1.

Transition de budget	Écart du F1 externe
10 vers 30 s	+0.0217
30 vers 60 s	-0.0217
60 vers 120 s	+0.0173

Un budget plus long peut consacrer du temps à des candidats qui n'améliorent pas le score externe. La perte de validation guide la recherche ; elle ne garantit pas que chaque gagnant successif sera meilleur sur un test indépendant. L'intérêt de l'AutoML inclut aussi la diversité explorée et le temps de réglage manuel économisé.

5. Bloc C : inspecter la recherche de 60 s



Capture 4 - Vue de lecture de la sortie réelle de src/inspecter.py sur le journal de 60 s.

Famille essayée	Nombre de candidats	Meilleur F1 de validation
lgbm	39	0,8262
xgboost	20	0,8218
xgb_limitdepth	1	0,7952
rf	9	0,6624
extra_tree	8	0,1302
lrl1	1	0,0795
sgd	9	0,0681

Le journal de 60 s contient 87 essais lisibles. Chaque ligne conserve notamment learner, config, validation_loss et wall_clock_time. Le F1 de validation est calculé comme 1 - validation_loss. La configuration gagnante est conservée dans le JSON du budget et comme artefact MLflow.

```
{
  "n_estimators": 104,
  "num_leaves": 4,
  "min_child_samples": 43,
  "learning_rate": 0.6558491573833527,
  "log_max_bin": 5,
  "colsample_bytree": 0.9051169955870563,
  "reg_alpha": 0.0009765625,
  "reg_lambda": 6.492993307502377
}
```

6. Bloc D : la fuite de données

num_dossier_litige est construit après la contestation d'une fraude : il vaut un numéro pour les fraudes de l'historique, zéro sinon. Cette information n'existe pas pendant le paiement. Le test aléatoire conserve pourtant cette relation artificielle dans train et test.



Capture 5 - Sortie complète de la démonstration locale de fuite de données.

Situation évaluée	F1 mesuré
Historique avec numéro de litige	1,0000
Production simulée : numéro toujours à zéro	0,0000

La famille retenue est lgbm. Le modèle exploite une variable qui révèle la réponse après l'événement ; il n'en connaît pas la disponibilité métier. Mettre cette colonne à zéro simule l'information réellement disponible au paiement. Il ne s'agit pas d'un déploiement en production.

Pour détecter le problème avant déploiement : auditer la date de création des variables, interdire les informations postérieures à la décision, examiner les importances et évaluer un jeu temporel reconstruit avec les seules données disponibles en ligne.

7. Bloc E : comparatif des approches locales

Le tableau reports/comparatif.md est complété avec les mesures ci-dessous. Pour rester lisible, ses critères sont présentés en deux parties dans ce rapport. Les temps humains sont des estimations de préparation, pas un chronométrage des étudiants.

Approche	F1 test	Temps humain estimé	Temps machine mesuré
Logistique	0,7407	5-15 min	0.0827 s
Manuel TP2	0,8669	30-60 min de réglage	1.3822 s (réentraînement)
FLAML 60 s	0,8409	10-20 min de configuration	60.571 s

Approche	Explicabilité	Export / réversibilité
Logistique	Coefficients lisibles ; attention à l'échelle des variables.	Modèle et code locaux ; conserver les dépendances.
RF manuel	Importances et analyse d'erreurs ; moins direct qu'une logistique.	Code et modèle locaux ; environnement reproductible.
FLAML	Journal et configuration inspectables ; explication selon la famille.	Estimateur local ; enregistrer les transformations et l'environnement.

Le coût local n'est pas nul

La recherche de 60 s a duré 60.571 s. Aucune facture cloud n'est générée, mais il reste le coût du matériel, de l'énergie et du travail humain. À puissance supposée constante de 60 W, ce fit représenterait 0.001010 kWh. La puissance et le prix de l'électricité n'ont pas été mesurés : il s'agit d'un calcul illustratif.

Recommandations 1 et 2 sur les cinq du comparatif

1. Utiliser la logistique pour un premier repère rapide et lisible ; préférer le réglage manuel lorsqu'une expertise sur une famille est déjà disponible.
2. Utiliser FLAML pour explorer plusieurs familles sous budget, puis juger le gain avec le coût de calcul et les besoins d'explication.

8. Bloc E : plateformes cloud managées

Exploration documentaire du 22 octobre 2026. Aucun compte créé, aucune ressource cloud lancée : les F1 et temps machine cloud sont non mesurés. Les montants sont en USD, hors taxes, indicatifs et à confirmer selon région et contrat. Sources [G], [A] et [M] en fin de rapport.

Plateforme	Prérequis et coût documentaire	Explications / suivi	Export
Vertex AI AutoML	Projet, facturation, IAM/API et quotas. Tarif tabulaire affiché : 21,252 USD/nœud-heure ; endpoint et inférence en plus [G1-G2].	Évaluations, attributions selon le mode de service, entraînements et versions.	Classification/régression exportable vers Docker ; CPU x86/AVX ; pas d'explications Vertex sur export ; forecasting exclu [G3].
SageMaker Autopilot / Canvas	Compte AWS, IAM, S3 et quotas. Session : 1,90 USD/h. Exemple training <100 Mo : 2,3-9,2 USD ; hébergement séparé [A1-A3].	Candidats, métriques, importances, rapports et notebooks pour le tabulaire.	Artefacts S3 et conteneurs accessibles ; transformations et environnement à reproduire [A4].
Azure Automated ML	Abonnement, workspace, droits et quota de VM. VM × durée + services ; pas de supplément Azure ML annoncé [M1-M3].	Jobs/enfants, métriques, prétraitements, modèle et importance des variables.	Téléchargement du modèle, script de scoring et environnement [M4].

Temps humain indicatif pour chaque plateforme : 30-90 min de configuration avec compte déjà disponible ; non mesuré. Les services managés peuvent réduire l'effort d'exploitation, mais nécessitent la maîtrise des données, droits et coûts.

Recommandations 3 à 5

3. Vertex AI convient si les données et l'exploitation sont déjà chez Google ; vérifier les contraintes d'export.
4. Autopilot/Canvas convient à une équipe AWS recherchant une interface low-code et des candidats documentés.
5. Azure Automated ML convient à une équipe Azure ; pour les trois, contrôler coûts, fuite, accès et portabilité.

La réversibilité n'est pas simplement « impossible sur le cloud » : distinguer le téléchargement d'un modèle de la reproduction de ses prétraitements, de son environnement, de ses explications et de son monitoring.

9. Réponses aux questions 1 à 3

1. Réglage manuel ou AutoML ?

FLAML 60 s obtient 0,8409, contre 0,8669 pour le RF manuel, soit -0.0260. Une différence faible ne supprime pas l'intérêt de l'AutoML : il explore plusieurs familles et configurations sans écrire chaque grille. Il faut cependant juger le gain, la stabilité, l'interprétabilité et les erreurs métier. Une différence sur ce seul jeu externe ne prouve pas un avantage général.

2. Quel est le coût réel ?

Le fit local a duré 60.571 s. L'énergie, l'amortissement, la préparation et la validation restent à notre charge. Dans le cloud, additionner les ressources multipliées par leur durée, puis les sessions, le stockage et l'inférence. Un budget FLAML de 60 s n'équivaut pas à un job managé de 60 s.

Exemples documentaires : 21,252 USD/nœud-heure donnent 0,3542 USD par minute de nœud par simple conversion, sans constituer un devis Vertex. Canvas ajoute une session horaire et ses entraînements. Pour Azure, la page consultée ne restitue pas de tarif VM chiffré : une VM supposée à 0,20 USD/h coûterait 0,00333 USD pour une minute de compute seul, mais ce taux est une hypothèse, pas un tarif Azure vérifié.

3. Qu'est-ce qui reste à notre charge ?

Premièrement, définir le problème, contrôler les labels et vérifier que les variables sont disponibles au moment de décider. Deuxièmement, concevoir une évaluation sans fuite, avec un découpage et une métrique adaptés au coût des erreurs. Troisièmement, organiser la validation humaine, la sécurité, les coûts, la traçabilité et le suivi de dérive en exploitation.

10. Réponses aux questions 4 à 6

4. Quand préférer le managé ou le local ?

Le managé est pertinent pour une équipe déjà organisée dans ce cloud, ayant besoin de calcul élastique, de droits partagés, d'un registre et d'endpoints exploités collectivement. Le local convient à ce petit jeu de 5 000 lignes et à une expérimentation sous budget limité. Comparer le coût complet et l'effort d'exploitation, pas seulement le temps de fit.

5. Quelles informations pour un secteur régulé ?

Il faut pouvoir documenter la provenance et les versions des données, la disponibilité temporelle des variables, les transformations, les essais et réglages, le protocole d'évaluation et les erreurs par sous-groupe. Le code, l'environnement, le modèle, les accès, les validations et décisions de promotion doivent être auditables. Des explications et limites sont nécessaires ; un simple classement d'importances ne prouve ni conformité ni absence de fuite.

6. Pourquoi l'effondrement avec la fuite ?

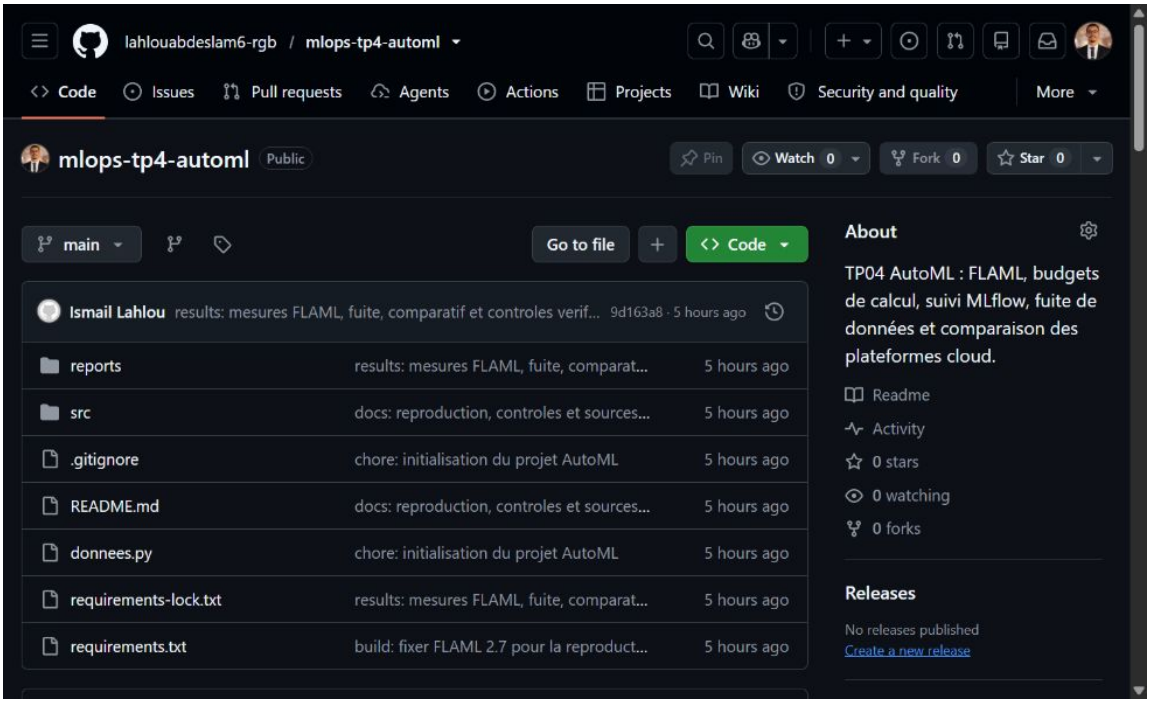
Le score passe de 1,0000 sur l'historique piégé à 0,0000 en production simulée. Le numéro du litige révèle une fraude après contestation ; il n'est pas connu au paiement. Le découpage aléatoire conserve ce raccourci dans l'historique. FLAML optimise sa métrique et ne vérifie pas la chronologie métier.

Avant de déployer, reconstruire les variables avec leur date réelle de disponibilité, éliminer les informations postérieures et refaire une évaluation temporelle. Une chute du score dans ces conditions révèle une fragilité que l'optimisation d'hyperparamètres ne résout pas.

Bilan

Le TP relie résultats, durée, candidats essayés et limites. L'AutoML automatise une recherche ; la validité des données, de l'évaluation et de l'usage reste sous responsabilité humaine. Les résultats mesurés et les journaux sont publiés avec le code pour permettre leur inspection.

11. Publication, contrôles et sources



Dépôt public mlops-tp4-automl : code, résultats, journaux et documentation.

https://github.com/lahlouabdeslam6-rgb/mlops-tp4-automl

Les contrôles vérifient le volume des données, les indices disjoints, les six runs terminés, les quatre journaux non vides, leur minimum de perte, les artefacts MLflow, le F1 manuel et la chute provoquée par la fuite. data/, .venv/, mlflow.db et mlartifacts/ sont ignorés par Git. reports/ contient les preuves demandées.

Sujet : TP04_AutoML_LowCode.pdf, module Déploiement d'IA, 2026-2027. Sources officielles consultées le 22/10/2026 ; liens complets conservés dans reports/sources_cloud.md. Les anciennes pages Vertex peuvent rediriger vers les nouvelles rubriques Gemini Enterprise Agent Platform.

[G1] Entraînement tabulaire

[G2] Tarification Google

[G3] Export tabulaire

[A1] SageMaker Autopilot

[A2] Tarification Canvas

[A3] Quotas Autopilot

[A4] Artefacts et déploiement

[M1] Azure Automated ML

[M2] Tarification Azure ML

[M3] Quotas Azure ML

[M4] Export et scoring